

MASTER 2 DATA ANALYTICS_SPRING

Stats Décisionnelles — Projet Final

Année universitaire 2026–2027

Analyse des Ventes E-Commerce

Online Retail

Indicateurs de performance, segmentation client et leviers stratégiques

Rapport synthétique

541 909 transactions · 4 338 clients · 3 922
produits

Période : Décembre 2010 – Décembre 2011

*Python · pandas · scikit-learn · statsmodels ·
matplotlib · seaborn*

Membres du Groupe :

- EL FATHY Ghita,
- NGUYEN Hai Yen,
- AKE Akebrou Marie-Ange,
- AMBETO Beni,
- ZHOU Ruolin,
- ELBAHWI Haroune

Table des matières

Introduction	3
1. Préparation des données.....	3
2. Analyse exploratoire (EDA)	3
2.1 Indicateurs globaux	3
2.2 Répartition géographique du chiffre d'affaires.....	3
2.3 Top 10 produits par quantité vendue	4
2.4 Saisonnalité.....	4
3. Visualisations clés.....	4
4. Statistiques descriptives et corrélations	7
4.1 Indicateurs de tendance et de dispersion	7
4.2 Matrice de corrélation (Pearson)	7
4.3 Lecture business	7
5. Test statistique : ANOVA	8
5.1 Hypothèses et méthodologie	8
5.2 Résultats.....	8
5.3 Interprétation business.....	8
6. Régression linéaire multiple.....	8
6.1 Modèle estimé	8
6.2 Résultats.....	9
6.3 Interprétation business.....	9
7. Segmentation client par K-Means	9
7.1 Construction des indicateurs RFM.....	9
7.2 Standardisation et choix de k.....	9
7.3 Profiling des 4 clusters	9
7.4 Questions de synthèse.....	11
8. Recommandations stratégiques	12
8.1 Actions prioritaires par segment	12
8.2 Détail des deux actions prioritaires	12
8.3 Actions complémentaires	12
9. Limites de l'analyse.....	13
9.1 Variables insuffisantes ou absentes du dataset	13
9.2 Limites structurelles de l'analyse	13
10. Conclusion	14

Introduction

Online Retail est un site d'e-commerce britannique spécialisé dans la vente de cadeaux et d'articles de décoration. Le dataset UCI Machine Learning Repository couvre la période **décembre 2010 – décembre 2011**, soit un an d'activité transactionnelle complète sur 541 909 lignes brutes.

Ce rapport présente l'analyse complète de ces données de ventes. L'objectif est de produire des indicateurs de performance, d'identifier les leviers d'optimisation stratégique et de segmenter la clientèle pour mieux orienter les décisions marketing et assurer la pérennité commerciale du site.

Notre analyse se structure en trois volets : une analyse exploratoire (EDA) dressant un état des lieux du CA, des produits et de la saisonnalité ; des analyses statistiques inférentielles (statistiques descriptives, ANOVA, régression linéaire multiple) validant nos hypothèses ; et une segmentation client par K-Means débouchant sur des recommandations marketing actionnables.

Les analyses ont été conduites sous Python avec les bibliothèques pandas, matplotlib, seaborn, scikit-learn et statsmodels.

1. Préparation des données

Le jeu de données brut comporte 541 909 lignes sur 8 colonnes (**InvoiceNo**, **StockCode**, **Description**, **Quantity**, **InvoiceDate**, **UnitPrice**, **CustomerID**, **Country**). Trois opérations principales de nettoyage ont été menées :

- **Suppression des transactions annulées** (InvoiceNo commençant par « C ») : 9 288 lignes supprimées.
- **Valeurs manquantes** : 134 697 entrées sans CustomerID (~25 % des lignes) et 1 454 sans Description.
- **Doublons** : 5 231 lignes supprimées.

Le séparateur décimal a été corrigé, les dates converties au format datetime, et les valeurs aberrantes éliminées. Quatre colonnes dérivées ont été ajoutées : TotalPrice (= Quantity × UnitPrice), Year, Month et DayOfWeek.

Dataset final : 524 878 lignes × 13 colonnes, soit 96,9 % du volume initial conservé.

2. Analyse exploratoire (EDA)

2.1 Indicateurs globaux

Indicateur	Valeur
Commandes uniques	19 960
Clients uniques	4 338
Produits uniques (StockCode)	3 922
Chiffre d'affaires total	10 642 110,80 £
Période couverte	Déc. 2010 – Déc. 2011

2.2 Répartition géographique du chiffre d'affaires

Rang	Pays	CA (£)	Part
1	United Kingdom	9 001 744 £	84,6 %
2	Netherlands	285 446 £	2,7 %
3	EIRE	283 140 £	2,7 %
4	Germany	228 678 £	2,1 %
5	France	209 625 £	2,0 %
6	Australia	138 453 £	1,3 %

Le Royaume-Uni concentre à lui seul 84,6 % du CA, révélant une forte dépendance au marché domestique. Les marchés internationaux restent marginaux mais cohérents : Pays-Bas, Irlande et Allemagne forment un second groupe à fort potentiel d'expansion européenne.

2.3 Top 10 produits par quantité vendue

Les deux références leaders — « Paper Craft, Little Birdie » (80 995 unités) et « Medium Ceramic Top Storage Jar » (78 033 unités) — se détachent nettement du reste. Les produits du top 10 appartiennent tous à la catégorie **décoration et cadeaux à faible prix unitaire**, ce qui explique les volumes élevés. Cette concentration constitue un levier stratégique via une mise en avant ciblée et des offres de bundling.


(voir Figure 3 — Top 10 produits – Quantité vendue)

2.4 Saisonnalité


Le CA mensuel révèle une forte saisonnalité avec un pic marqué en novembre 2011, suivi d'une chute en décembre (données incomplètes). L'analyse par jour de la semaine montre que le mardi et le jeudi génèrent les plus forts CA, tandis que le samedi est très faible et le dimanche quasi nul — pattern qui suggère une clientèle commandant principalement en semaine.

3. Visualisations clés


Figure 1 — Évolution mensuelle du chiffre d'affaires (en milliers £)




La courbe confirme la trajectoire ascendante de 2011 et le pic d'activité de novembre, principal contributeur au CA annuel. La forte saisonnalité justifie une stratégie marketing calée sur le calendrier commercial.

Figure 2 — Top 10 des pays par chiffre d'affaires

La domination britannique est telle que les autres marchés sont visuellement écrasés sur l'échelle linéaire. Le Royaume-Uni représente **84,6 % du CA total (9 001 744 £)**. Les Pays-Bas, l'Irlande et l'Allemagne constituent le second groupe à ~228–285 k£, soit 30 fois moins.


Figure 3 — Top 10 produits – Quantité vendue

Les deux leaders **Paper Craft Little Birdie** (80 995 unités) et **Medium Ceramic Top Storage Jar** (78 033 unités) dominent nettement le classement, suivis par *World War 2 Gliders* (~55 000 unités). Les sept références suivantes se situent dans une fourchette resserrée entre 26 000 et 48 000 unités. **Ces 10 produits représentent ~9 % du volume vendu pour seulement 0,25 % du catalogue** — distribution typique de Pareto.

Figure 4 — Chiffre d'affaires par jour de la semaine


Ventes par jour de la semaine : le mardi et le jeudi génèrent les CA les plus élevés, tandis que le samedi est très faible et le dimanche quasi nul — cohérent avec une clientèle qui commande principalement en semaine.

Figure 5 — Distribution du TotalPrice (échelle logarithmique)



Distribution du TotalPrice : La distribution (en échelle log) est fortement asymétrique à droite : la très grande majorité des transactions se situent entre £0 et £25, ce qui traduit un profil de petites commandes fréquentes. Les quelques transactions à fort montant constituent des outliers qui gonflent la moyenne sans être représentatifs du comportement typique d'achat.

Figure 6 — Heatmap des corrélations



Heatmap des corrélations : TotalPrice est fortement corrélé à Quantity ($r = 0.907$), ce qui est attendu mécaniquement. La corrélation avec UnitPrice est faible ($r = 0.137$), indiquant que les revenus élevés sont davantage tirés par les volumes que par les prix. La corrélation quasi nulle entre Quantity et UnitPrice ($r = -0.004$) confirme l'absence de stratégie de remise volume visible dans les données brutes.




Figure 7 — Heatmap : CA par Mois × Jour (en £k)

Heatmap Mois × Jour : La heatmap confirme la saisonnalité automne-hivernale (mois 10, 11, 12 les plus chauds) avec les jeudis et vendredis comme jours de pic en fin d'année. Décembre enregistre notamment le CA le plus élevé le vendredi (£410k), ce qui correspond aux achats de Noël de dernière minute.

4. Statistiques descriptives et corrélations

4.1 Indicateurs de tendance et de dispersion

Variable	Moyenne	Médiane	Écart-type	Variance
Quantity	10,62	4,00	156,28	24 423,45
UnitPrice (£)	3,92	2,08	36,09	1 302,71
TotalPrice (£)	20,28	9,92	271,69	73 817,39

La moyenne est supérieure au double de la médiane et l'écart-type dépasse largement la moyenne (CV = 1 340 % pour TotalPrice). Cette dispersion extrême révèle une distribution fortement asymétrique : médiane à 9,92 £ mais maximum à 168 469 £.

4.2 Matrice de corrélation (Pearson)

	Quantity	UnitPrice	TotalPrice
Quantity	1,000	-0,004	0,907
UnitPrice	-0,004	1,000	0,137
TotalPrice	0,907	0,137	1,000

4.3 Lecture business

Trois enseignements clés : (1) Double profil de clientèle — masse de petits acheteurs réguliers coexistant avec une minorité de clients à très fort volume. (2) Positionnement low-cost (75 % des articles < 4,13 £) impose une stratégie volume. (3) Élasticité-prix faible (corrélations Quantity ↔

$UnitPrice = -0,004$) : les promotions quantité sont mécaniquement plus efficaces que les rabais unitaires.

5. Test statistique : ANOVA

5.1 Hypothèses et méthodologie


Le test ANOVA à un facteur vérifie si le montant moyen des commandes diffère significativement selon le pays. Données agrégées au niveau commande, seuls les pays comptant ≥ 30 commandes retenus (14 pays).

- H_0 : Le montant moyen des commandes est identique pour tous les pays.
- H_1 : Au moins un pays présente un montant moyen significativement différent.

5.2 Résultats

Indicateur	Valeur
F-statistique	22,2486
p-value	$1,13 \times 10^{-53}$
Décision ($\alpha = 0,05$)	Rejet de H_0

Figure 8 — Distribution des montants par pays (8 pays principaux)



5.3 Interprétation business

La p-value ($1,13 \times 10^{-53}$) est infiniment inférieure à 0,05 : H_0 est rejetée avec très haut niveau de confiance. La valeur $F = 22,25$ indique que la variance entre pays est 22 fois supérieure à la variance intra-pays. Le boxplot révèle deux typologies : marchés à fort panier moyen (Pays-Bas, EIRE, Australie) et marchés à panier plus modeste mais à fort volume de commandes (UK).

Implication : une stratégie commerciale différenciée par marché s'impose — conditions avantageuses sur les volumes pour les marchés à fort panier, politique orientée fréquence et réachat pour le UK.

6. Régression linéaire multiple

6.1 Modèle estimé

Le modèle OLS explique le TotalPrice à partir de Quantity, UnitPrice, DayOfWeek et Country (dummy, UK = référence). Seuls les pays représentant $\geq 0,5$ % des transactions conservés (505 281 observations).

6.2 Résultats

R ²	R ² ajusté	F-statistique	p-value globale
0,8446	0,8446	457 678	≈ 0

Variable	Coefficient	p-value	Significatif
Constante	+1,5428	0,2136	Non
Quantity	+1,5811	< 0,001	Oui ***
UnitPrice	+1,0619	< 0,001	Oui ***
DayOfWeek	-0,1275	0,1225	Non

6.3 Interprétation business

Le modèle explique 84,5 % de la variance du TotalPrice — excellent pour des données réelles. Chaque unité supplémentaire commandée augmente le TotalPrice de 1,58 £ (≈ prix unitaire moyen). Quantity et UnitPrice sont les seuls leviers opérationnels structurants.

Insight contre-intuitif : le jour de la semaine n'a aucun effet significatif sur le panier individuel ($p = 0,12$). Des campagnes de lissage sur les jours à faible volume restent pertinentes pour optimiser la charge logistique, pas le panier.

7. Segmentation client par K-Means

7.1 Construction des indicateurs RFM

À partir des 524 878 transactions nettoyées, données agrégées au niveau CustomerID pour 4 338 clients. Quatre indicateurs comportementaux construits, date de référence : 10 décembre 2011.

Indicateur	Description	Moyenne	Médiane
MontantTotal	Dépense totale cumulée (£)	2 048,69 £	668,57 £
NbAchats	Nombre de commandes distinctes	4,27	2,00
QteTotal	Quantité totale d'articles	1 187,64	378,00
Récence	Jours depuis le dernier achat	92,5 j	51,0 j

7.2 Standardisation et choix de k

Variables standardisées par Z-score (indispensable — Récence : 1–374 j vs MontantTotal : 3,75–280 206 £). La méthode du coude révèle une inflexion entre $k=3$ et $k=4$; $k=4$ retenu pour le meilleur compromis granularité/interprétabilité.

7.3 Profiling des 4 clusters

Cluster	Effectif	Montant moy.	NbAchats	QteTotal	Récence
0 — Réguliers	3 284 (75,7 %)	1 670,9 £	4,5	987,2	41,8 j
1 — VIP extrêmes	7 (0,2 %)	184 080 £	65,4	89 627	6,7 j

Cluster	Effectif	Montant moy.	NbAchats	QteTotal	Récence
2 — Dormants	1 079 (24,9 %)	518,3 £	1,6	266,6	247,1 j
3 — Gros acheteurs	48 (1,1 %)	35 121 £	42,9	22 371	17,5 j


Cluster 0 — Réguliers (75,7 %) : cœur de la clientèle, achètent 4,5 fois en moyenne pour 1 670 £ cumulés, dernier achat < 42 j.

Cluster 1 — VIP extrêmes (0,2 %) : 7 clients à 184 080 £ moyen — profil à très fort volume d'achat. Récence 6,7 j = engagement quasi-permanent.

Cluster 2 — Dormants (24,9 %) : 1 079 clients sans achat depuis ~247 j. Arrêt après 1–2 commandes. Risque de perte définitive.


Cluster 3 — Gros acheteurs actifs (1,1 %) : 48 clients à 35 121 £, récence 17,5 j. Vivier de futurs VIP.

Figure 9 — Méthode du coude – Choix du k optimal



Lecture — La courbe représente l'inertie intra-cluster en fonction du nombre de clusters testés (k de 2 à 10). Elle décroît rapidement entre k=2 et k=4, puis s'aplatit nettement au-delà : c'est le « coude » de la méthode, qui signale k=4 comme valeur optimale. Au-delà, augmenter k n'améliore plus significativement la compacité des clusters tout en complexifiant l'interprétation business — ce choix offre le meilleur compromis entre granularité et lisibilité des segments

Figure 10 — Récence vs Montant total – Segmentation client



Lecture Ce nuage de points croise la Récence (axe X, en jours) et le Montant Total dépensé (axe Y, en £), chaque point étant coloré selon son cluster d'appartenance. Deux populations se détachent visuellement : à gauche, une majorité de clients récents avec des montants modérés (Clusters 0 et 1, en bleu), et à droite, une masse de clients dormants depuis plus de 150 jours (Clusters 2 et 3, en

vert). Cette séparation nette confirme le pouvoir discriminant de la Récence comme axe principal de segmentation.

7.4 Questions de synthèse

Question 1 — Quels indicateurs ont le plus influencé la segmentation ? Pourquoi ?

MontantTotal est l'indicateur le plus discriminant. En K-Means, c'est la variance inter-individus qui guide la formation des clusters : or MontantTotal présente la plage la plus large du dataset (de 3,75 £ à 280 206 £, soit un rapport de 1 à 74 000). C'est lui qui crée la séparation la plus nette entre les clients à très haute valeur (Clusters 1 et 3) et le reste de la base. Même après standardisation Z-score, cette dispersion extrême reste la force de séparation dominante de l'algorithme.

La Récence est le second indicateur structurant. Elle sépare de façon nette les clients actifs (Clusters 0, 1, 3 — récence médiane < 42 j) des clients inactifs (Cluster 2 — récence moyenne 247 j). Cette coupure à ~8 mois d'inactivité est suffisamment franche pour que l'algorithme l'identifie systématiquement comme frontière de cluster.

NbAchats et QteTotal jouent un rôle secondaire d'affinage. Fortement corrélés au MontantTotal, ils apportent peu d'information indépendante. Ils permettent toutefois de distinguer le Cluster 3 (NbAchats = 42,9) du Cluster 1 (NbAchats = 65,4) à l'intérieur du groupe à haute valeur.

Question 2 — Quel cluster semble le plus stratégique commercialement ?

Le **Cluster 3 — Gros acheteurs actifs** est le cluster le plus stratégique, pour trois raisons cumulées.

1. Potentiel de conversion immédiat. Ces 48 clients présentent exactement le profil des VIP extrêmes à un stade antérieur : 35 121 £ de dépenses, 42,9 commandes, récence de 17,5 j. La distance RFM entre ces deux clusters est la plus faible de l'ensemble — ce sont les candidats naturels à la promotion vers le statut VIP.

2. ROI mécaniquement favorable. Le coût d'acquisition est déjà amorti. Chaque livre investie dans leur fidélisation s'applique sur une base de 35 121 £ de CA existant, contre 1 670 £ pour un régulier — soit un levier de rendement 21 fois supérieur.

3. Espace de croissance encore disponible. Contrairement au Cluster 1 dont l'engagement est déjà maximal (récence 6,7 j, 65 commandes/an), le Cluster 3 présente encore un potentiel d'augmentation de fréquence et de panier.

Note : le Cluster 1 reste la priorité absolue en protection du CA existant — la perte d'un seul VIP extrême équivaut à 110 clients réguliers. Mais en termes de croissance actionnable, c'est le Cluster 3 qui offre le plus grand potentiel.

Question 3 — Deux actions marketing basées sur les résultats

Action 1 — Programme d'accompagnement VIP pour le Cluster 3

Dimension	Détail
Segment ciblé	Cluster 3 — 48 Gros acheteurs actifs (35 121 £ moyens, récence 17,5 j)
Insight data	Ces clients ont le même profil que les VIP extrêmes à un stade antérieur. La régression confirme que quantité et prix unitaire sont les seuls leviers du panier.
Action concrète	Contact nominatif via account manager : statut VIP avec paliers de remise progressifs (−5 % à 30k£, −10 % à 50k£), accès prioritaire aux nouveautés, conditions de paiement à 30 j.
KPI de suivi	Taux de conversion Cluster 3 → Cluster 1 à 12 mois, évolution du MontantTotal moyen.
ROI attendu	Conversion de 10 % (5 clients) vers profil VIP = +1,5M£ de CA additionnel potentiel.

Action 2 — Campagne de réactivation pour le Cluster 2

Dimension	Détail
Segment ciblé	Cluster 2 — 1 079 Dormants (518 £ moyens, inactifs depuis 247 j en moyenne)
Insight data	Ces clients ont déjà commandé (NbAchats = 1,6). Leur inactivité est un désengagement progressif, pas un rejet — encore réversible à ce stade.
Action concrète	Séquence e-mail 3 temps sur 30 jours : J+0 rappel personnalisé avec recommandations produits ; J+10 offre –15 % valable 15 jours ; J+25 dernière relance avant archivage du profil.
KPI de suivi	Taux d'ouverture, taux de réactivation (commande dans les 30 j), CA récupéré.
ROI attendu	10 % de réactivation (107 clients) × 518 £ = +55 000 £ de CA récupéré à coût marginal quasi nul.

8. Recommandations stratégiques

8.1 Actions prioritaires par segment

Cluster	Profil	Action recommandée	Priorité
0 — Réguliers	Actifs, panier moyen	Cross-sell / recommandations produits	★★★
1 — VIP extrêmes	Très haute valeur	Programme fidélité premium	★★★★★
2 — Dormants	Inactifs 8+ mois	Campagne e-mail réactivation –15 %	★★★★★
3 — Gros acheteurs	Fort potentiel VIP	Accompagnement vers statut VIP	★★★★★

8.2 Détail des deux actions prioritaires

Action 1 — Programme de fidélité VIP (Clusters 1 et 3)

Ces 55 clients génèrent une part disproportionnée du CA. Un programme dédié — accès prioritaire aux nouveautés, gestionnaire de compte personnel, remises sur volumes, conditions de paiement étendues — permettrait de sécuriser leur engagement. Le coût d'acquisition étant amorti, le ROI est mécaniquement très favorable.

Action 2 — Campagne de réactivation (Cluster 2)

1 079 clients inactifs depuis 8+ mois représentent un CA potentiel récupérable. Une séquence d'e-mails avec offre –15 % (valable 30 jours) peut récupérer une fraction à moindre coût avant perte définitive.

8.3 Actions complémentaires

- **Cross-sell Cluster 0** : recommandations produits personnalisées pour augmenter le panier moyen sans coût d'acquisition.
- **Onboarding renforcé** : séquence automatisée (e-mail de bienvenue, bestsellers, bon –10 % sur le 2^e achat) pour réduire le taux de one-shot.
- **Différenciation géographique** : conditions avantageuses sur les volumes pour les marchés à fort panier moyen (NL, EIRE, AU), orientation fréquence et réachat pour le UK.

9. Limites de l'analyse

Cette section présente les limites méthodologiques identifiées dans notre démarche. Elles ne remettent pas en cause la validité des résultats, mais circonscrivent leur portée et indiquent les axes d'enrichissement possibles.

9.1 Variables insuffisantes ou absentes du dataset

Variable	Ce qu'elle contient	Ce qu'elle ne permet pas
CustomerID	Identifiant client (absent dans 25 % des lignes)	Distinguer le profil d'acheteur, relier les transactions anonymes à un individu, calculer un taux de churn fiable. Les 134 697 lignes sans CustomerID sont exclues de la segmentation, ce qui biaise potentiellement les effectifs des clusters — en particulier le Cluster 2 (Dormants).
StockCode / Description	Référence et libellé produit brut	Catégoriser les produits sans traitement manuel. Sans taxonomie produit, la segmentation RFM est aveugle aux préférences d'achat de chaque cluster.
Quantity	Nombre d'unités commandées	Distinguer un achat de consommation courante d'un achat de stock ponctuel. Une commande de 500 unités et une commande de 5 unités sont traitées identiquement par le modèle.
UnitPrice	Prix unitaire affiché	Savoir si une remise a été appliquée, identifier des prix négociés ou promotionnels. Un prix de 1,25 £ peut être le tarif catalogue ou un tarif après remise de 40 %.
InvoiceDate	Date de la commande (jour)	Analyser le comportement intraday (heure de commande) ni détecter des patterns de réapprovisionnement.
Country	Pays associé à la transaction	Confirmer s'il s'agit du pays de résidence du client, de livraison ou du siège social. Un même client peut apparaître sous plusieurs pays.

9.2 Limites structurelles de l'analyse

Fenêtre temporelle unique (12 mois). L'ensemble du dataset couvre une seule année (décembre 2010 – décembre 2011). Il est impossible de distinguer une tendance structurelle d'un comportement conjoncturel, ni de valider la stabilité des clusters dans le temps. Un deuxième exercice fiscal permettrait de confirmer ou d'infirmer les patterns saisonniers observés.

Absence de données de navigation et d'acquisition. Le dataset est purement transactionnel. On ne sait pas comment les clients ont trouvé le site, quelles pages ils ont consultées, ni pourquoi certains ont abandonné leur panier. Ces variables sont pourtant déterminantes pour comprendre le taux de one-shot élevé (médiane NbAchats = 2) et pour construire un scoring de churn prédictif.

Hypothèses d'interprétation non vérifiables. Certaines lectures du rapport (profils à fort volume d'achat assimilés à des acheteurs professionnels, marchés à fort panier moyen supposés être des marchés de volume) restent des inférences tirées des données transactionnelles. Elles sont cohérentes avec les chiffres mais ne peuvent pas être confirmées sans données de profil client déclaré.

Sensibilité de K-Means aux valeurs extrêmes. Les 7 clients du Cluster 1 (184 080 £ moyens) créent un cluster statistiquement valide mais numériquement instable — un seul client supplémentaire ou retiré peut modifier la géographie des clusters. Un clustering hiérarchique (méthode de Ward) ou DBSCAN aurait été plus robuste face à ces outliers, au prix d'une interprétabilité moindre.

10. Conclusion

Cette analyse a permis de produire un diagnostic complet du portefeuille de ventes Online Retail, à partir de 541 909 transactions brutes ramenées à 524 878 lignes valides après nettoyage. Les enseignements clés se structurent en quatre constats :

- **Concentration géographique** : le Royaume-Uni capte 84,6 % du CA, créant un risque de dépendance mais révélant un fort potentiel d'expansion européenne.
- **Hétérogénéité des marchés validée** : l'ANOVA ($F = 22,25$; $p = 1,13 \times 10^{-53}$) démontre que le comportement d'achat diffère structurellement selon les pays.
- **Modèle prédictif robuste** : la régression OLS ($R^2 = 0,8446$) identifie Quantity et UnitPrice comme les seuls leviers structurants du panier.
- **Segmentation actionnable** : 4 clusters distincts — 7 VIP extrêmes, 48 gros acheteurs, 3 284 réguliers, 1 079 dormants — chacun appelant des actions marketing ciblées.

Les recommandations s'articulent autour de deux priorités : sécuriser les clients à haute valeur (Clusters 1 & 3) via un programme fidélité dédié, et réactiver les dormants (Cluster 2) avant perte définitive. Combinée à une différenciation des conditions par marché, cette approche maximise le ROI marketing.

Lecture stratégique globale — Online Retail présente un catalogue low-cost (75 % des articles < 4,13 £) avec une logique de volume élevé à marge unitaire faible. Deux risques majeurs émergent des données : (1) une dépendance critique aux 55 clients à fort volume qui concentrent une part disproportionnée du CA — leur perte serait irremplaçable à court terme ; (2) un taux de one-shot élevé (médiane NbAchats = 2) qui signale un déficit d'engagement post-premier achat. En parallèle, trois opportunités restent sous-exploitées : le potentiel des marchés déjà actifs (Pays-Bas, Allemagne, France, EIRE), le vivier de conversion Cluster 3 → Cluster 1, et l'automatisation CRM pour le cross-sell sur les 3 284 réguliers. La saisonnalité Q4 (pic novembre) impose enfin une planification stocks rigoureuse — toute rupture pendant cette fenêtre représente un CA définitivement perdu.

Cette analyse illustre la complémentarité des méthodes statistiques classiques (ANOVA, régression) et de l'apprentissage non supervisé (K-Means) pour transformer un volume massif de données transactionnelles en leviers de décision concrets. Elle peut être enrichie par des analyses avancées : scoring de churn prédictif, modélisation log-log pour la régression, ou approche RFM enrichie par des variables comportementales.