

Projet collectif – Analyse des ventes online retail**Contexte**

Vous êtes chargés d'analyser les données de ventes d'un site e-commerce afin de produire des indicateurs de performance et d'identifier des leviers d'optimisation stratégique.

Outils imposés : Python (pandas, matplotlib, seaborn, scikit-learn, statsmodels).

Travail demandé**1. Préparation des données**

- Importer et nettoyer les données : valeurs manquantes, doublons, types de données.
- Supprimer les transactions annulées (InvoiceNo commençant par "C").
- Créer une colonne TotalPrice = Quantity * UnitPrice.

Doublons parce que il y a plusieurs produits dans invoice> invoice doublons

2. Analyse exploratoire (EDA)

- Nombre total de commandes, de clients, de produits.
- Chiffre d'affaires total par pays.
- Top 10 des produits les plus vendus.
- Analyse de la saisonnalité : ventes par mois, jour, de la semaine, produit, vente no de commandex

3. Visualisations

- Histogrammes, courbes, heatmaps pour illustrer les ventes.
- Minimum 5 visualisations différentes.

4. Statistiques descriptives

- Moyennes, variances, écarts-types.
- Analyse de corrélations entre Quantity, UnitPrice, TotalPrice.

5. Test statistique : ANOVA

- Hypothèse : "Le montant moyen des commandes diffère selon les pays."

- Réaliser une **ANOVA** (TotalPrice ~ Country).
- Interpréter le résultat du test (p-value).

6. Régression linéaire multiple

- Modéliser le TotalPrice en fonction de :
 - Quantity
 - UnitPrice
 - Jour de la semaine (extrait de InvoiceDate)
 - Pays (encodé en variables fictives)
- Présenter coefficients, R^2 et interprétation pratique.

7. Analyse complémentaire : Segmentation client par clustering (K-means)

7.1. Construction d'indicateurs client

À partir des transactions, agréger les données au niveau CustomerID pour créer 4 indicateurs simples :

- Montant total dépensé
- Nombre total d'achats
- Quantité totale achetée
- Récence(jours depuis dernière commande)

Standardiser ensuite les variables pour permettre le clustering (z-score).

7.2. Segmentation par K-means

Vous devez ensuite :

1. Appliquer K-means pour différents nombres de clusters (2 à 6).
2. Utiliser uniquement l'inertie (méthode du coude) pour choisir un nombre de clusters raisonnable.
Pas d'indice de silhouette obligatoire pour alléger la charge.
3. Conserver le modèle retenu et attribuer à chaque client un numéro de cluster.

7.3. Profiling des segments

Décrire simplement les clusters obtenus à l'aide de statistiques descriptives :

- Moyenne / médiane des indicateurs dans chaque cluster
- 1 visualisation obligatoire :
 - boxplot par cluster ou
 - scatter plot en 2D (sur deux variables) avec couleurs de cluster

7.4. Interprétation marketing (data-driven)

À partir du profil des clusters, rédiger une interprétation marketing concise.

Vous devez proposer 2 à 4 actions marketing simples, réalistes et appuyées par les statistiques observées.

7.5. Questions de synthèse à inclure dans le rapport

1. Quels indicateurs ont le plus influencé la segmentation ? Pourquoi ?
2. Quel cluster semble le plus stratégique commercialement ?
3. Proposez deux actions marketing basées sur vos résultats.

Livrables

- Un **notebook Python** propre, commenté, réalisant toutes les analyses.= scripte python, notebook jupyter recommandé

- Un **rapport synthétique** (**maximum 10 pages**) résumant les méthodologies, résultats et recommandations stratégiques- avec canva ou powerpoint
- 15 mins pour chaque groupe q

Plan recommandé pour le rapport

1. Introduction - yen
2. Préparation des données -
3. Analyse exploratoire
4. Analyses statistiques (ANOVA, Régression)
5. Analyse segmentation client par clusters
6. Recommandations stratégiques
7. Conclusion

Grille d'évaluation partie support de présentation (noté sur 7 points)

Critère	points
Qualité du code Python	1,5
Pertinence des analyses exploratoires	1,5
Rigueur de l'ANOVA et de la Régression	1,5
Richesse et clarté des visualisations	1,0
Qualité de la segmentation client	1,0
Clarté et structure du rapport	0,5

Resultat

Répartition recommandée

 Binôme 1 — Données & Exploration

Sections : 1 + 2 + 3

Nettoyage des données, TotalPrice

EDA (commandes, clients, CA par pays, Top 10)

Visualisations (viz1 à viz7)

PPT : slides Introduction + Préparation des données + Analyse exploratoire

 Binôme 2 — Statistiques

Sections : 4 + 5 + 6

Statistiques descriptives (moyennes, variances, corrélations)

ANOVA + interprétation H_0/H_1

Régression linéaire multiple + interprétation des coefficients

PPT : slides Analyses statistiques

 Binôme 3 — Segmentation & Recommandations

Sections : 7 + Conclusion

K-Means (construction RFM, coude, profiling)

Interprétation marketing + questions de synthèse

Recommandations stratégiques + Conclusion

PPT : slides Segmentation + Recommandations + Conclusion